Sophia Nicole de Carvalho Mariano

Solução para a empresa LH Nautical

São Paulo

2026

Resumo

ESTE DOCUMENTO FOI GERADO PENSANDO EM RESOLVER O PROBLEMA APRESENTADO NO CENÁRIO QUE FOI DADO NO DESAFIO. AS RESPOSTAS DO QUESTIONÁRIO ESTÃO NO REPOSITORIO DO GITHUB INFORMADO NA PÁGINA DE CODIFICAÇÃO

Será apresentado por meio desse documento uma solução para o problema da empresa LH Nautical em relação a desorganização de dados

Foi utilizada a plataforma Databricks para o tratamento e futura orquestração de dados, usando as linguagens Python(PySpark) e SQL. O motivo da escolha foi pensando em uma plataforma que possibilita ter um datalake, fazer o processo de ETL e fazer dashboards com os dados.

O primeiro processo feito foi a criação do Schema datalake no catalogo lh_nautical para o armazenamento dos dados brutos recebidos para tratamento. Em seguida, foi criada a camada Schema Bronze onde os dados brutos foram transformados em tabelas e armazenados. Todas as colunas das tabelas deste schema são do tipo texto.

O próximo Schema a ser criado foi Silver, essa camada é importante para tratar os dados fazendo uma formatação, padronização, limpeza e modificando os tipos das colunas das tabelas.

A última etapa foi criação da Schema Gold, com as informações que estão nessa camada é possível fazermos analises, por exemplo: descobrir o prejuízo dos produtos, lucros dos clientes e entre outras coisas. Nela teremos as tabelas de dimensões e a fatos_vendas.

Codificação

Está pagina contém a explicação de cada etapa do processo de programação

Link do repositório com os notebooks (Comece a leitura pelo notebook bronze_to_silver[produtos]):

https://github.com/SophiaNCM/Desafio_indicium

Caso queira ir direto para as respostas do questionario: https://github.com/SophiaNCM/Desafio_indicium/tree/main/Quest%C3%B5es%20respondidas

- **Camada Bronze**
  Todos os arquivos que estavam no datalake foram transformados em tabelas delta e salvas no schema bronze_lh_nautical. Os tipos das colunas não foram alterados, ou seja, todas as colunas são do tipo texto.
  Nome das tabelas salvas:
  - tbl_ clientes
  - tbl_custos_importacao
  - tbl_produtos
  - tbl_vendas

- **Camada Silver**
  Nessa camada, foi criado o schema silver_lh_nautical para que seja possível fazer o tratamento de dados das tabelas que estão na camada bronze. Essa fase é importante para indicar os tipos certos das colunas das tabelas, transformando colunas com datas no tipo data, colunas com id em inteiro e colunas com dinheiro em decimal. Os dados foram formatados e padronizados, exemplo: datas foram formatadas para o padrão yyyy-MM-dd, ou seja, se a data está escrita 01/01/2025, ela foi formatada para 2025-01-01. Location em tbl_clientes antes era escrita com estado e cidade, essa coluna foi separada em duas: states e cidades.
  Nome das tabelas salvas:
  - tbl_ clientes
  - tbl_custos_importacao

- tbl_produtos
- tbl_vendas

- **Camada Gold**

  A camada Gold é a última camada criada, aqui os dados já foram tratados e estão prontos para comporem as tabelas dimensões e fatos_vendas. As analises serão feitas com os dados disponíveis nessa camada.

  Nome das tabelas salvas:
  - dim_clientes
  - dim_cidades
  - dim_cotacao_dolar
  - dim_custos_importacao
  - dim_estados
  - dim_produtos
  - fatos_vendas

Demonstração gráfica

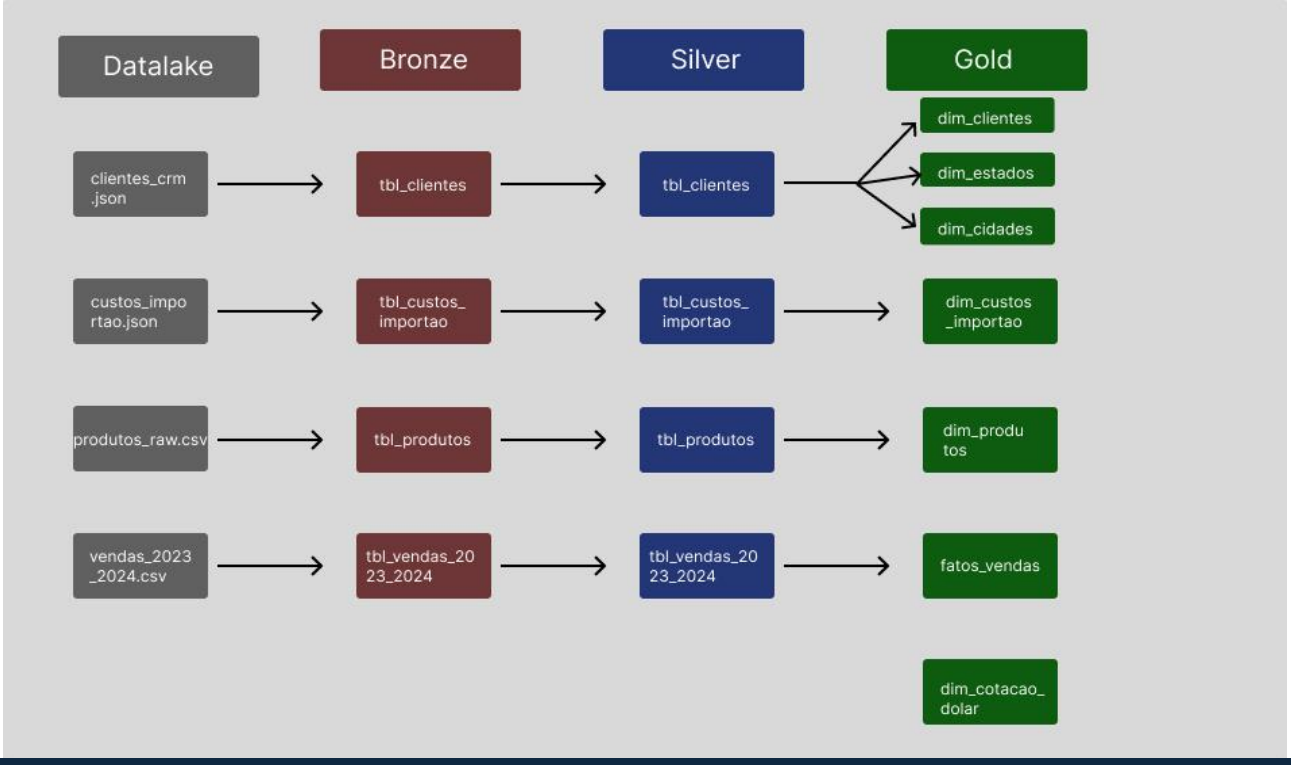

Solução

Para solucionar a grande dificuldade que a empresa LH Nautical enfrenta, a minha ideia foi:

- As tabelas da camada bronze são salvas com os dados brutos evitando que quebrem e evitando que eles sejam perdidos.
- As tabelas da camadas silver recebem os dados da camada bronze para formatação.
- As tabelas da camada gold são dados para analises.
- Limpeza de dados
    - Separar os estados das cidades, a tabela de clientes possuia uma coluna chamada location e ela armazenava a UF do estado junto ao nome da cidade, isso gerava erros e atrapalhava a filtragem. Essa coluna foi separada em duas: dim_estados e dim_cidades. Essa divisão foi feita pensando em evitar erros no momento da digitação e acontecer de cidades ou estados serem escritos duas vezes de formas diferentes.
- Padronização de dados
    - As colunas actual_category de produtos e category de custos importação foram padronizadas e formatadas para evitar erros em futuras consultas.
- Formatação de dados
    - Foi adotado um padrão de datas, pois algumas tabelas possuiam colunas com dois tipos de formtação, todas elas foram modificadas para o padrão yyyy MM-dd para evitar confusões.
    - Os e-mails dos clientes foram corrigidos, alguns dados possuiam # ao inves de @.
- Foi adicionada uma tabela com a cotação do dólar buscando facilitar a conversão do dólar para real dos preços de importação.
- Sugestões:
    - mudar os nomes das tabelas para inglês, tendo assim o nome da tabela e as colunas em inglês.
    - Buscar esclarecer se o total já possui o custo da importação
    - Sempre manter um padrão de escrita ao adicionar ou modificar um dado.

Dashboards

Analise dos produtos

Esse dashboard contém a quantidade de produtos, suas categorias, quantidade de produtos vendidos, os prejuízos e lucros de cada produto, valor total das vendas por mês e o valor total das vendas por ano.
Com isso é possivel analisar quais produtos geraram mais lucro e quais geraram mais prejuízo, qual o mês e o ano mais lucrativo, qual categoria gera mais lucro e quais gera mais prejuízo e fazer previsões sobre vendas e lucros para os próximos anos

Analise dos clientes

#	email	Quantidade comprada
1	lopes.alves.pacheco.rocha.carla@yahoo.com	233
2	márcia.figueiredo@protonmail.com	220
3	nunes.fernanda.soares.azevedo.vieira@outlook.com	220
4	lucas.lopes.guedes.cunha@tutanota.com	218
5	femininos.antunes.amaral.lopes.ribeiro@icloud.com	217
6	guedes.cunha.costa.diego@outlook.com	217
7	ribeiro.francisca.pinheiro@aol.com	215
8	torres.oliveira.peixoto.letícia@yahoo.com	213
9	martins.guimarães.carlos@hotmail.com	213
10	farias.jéssica.cunha@outlook.com	213

#	nome do cliente	email	lucro
1	Daniela Teixeira	antunes.coelho.batista.teixeira.daniela@hotmail.com	R$66.42K
2	Luiz Borges	gomes.araújo.borges.luiz@hotmail.com	-R$53.64K
3	Femininos Antunes	femininos.antunes.amaral.lopes.ribeiro@icloud.com	-R$71.08K
4	Jéssica Pimentel	nunes.borges.teixeira.pimentel.jéssica@yahoo.com	-R$127.37K
5	Bruna Mendonça	rodrigues.mendonça.bruna@aol.com	-R$137.87K
6	Femininos Oliveira	femininos.oliveira.antunes@icloud.com	-R$139.80K
7	Victor Araújo	araújo.tavares.azevedo.victor.correia@gmail.com	-R$151.53K
8	Pedro Freitas	pedro.freitas@icloud.com	-R$157.15K
9	Pedro Ribeiro	costa.correia.ribeiro.santos.pedro@yahoo.com	-R$167.96K
10	Bianca Rodrigues	rodrigues.bianca@icloud.com	-R$194.58K

Esse dashboard apresenta informações como: quantidade de clientes, quantidade de clientes por estados, quantidade de compras realizadas por clientes, categoria dos produtos e o lucro gerado por cada cliente

Com essas informações é possível analisar quais os clientes mais lucrativos, quais efetuam mais compras, qual a região com maior quantidade de clientes, qual a categoria dos itens mais comprados

Vendas médias por semana

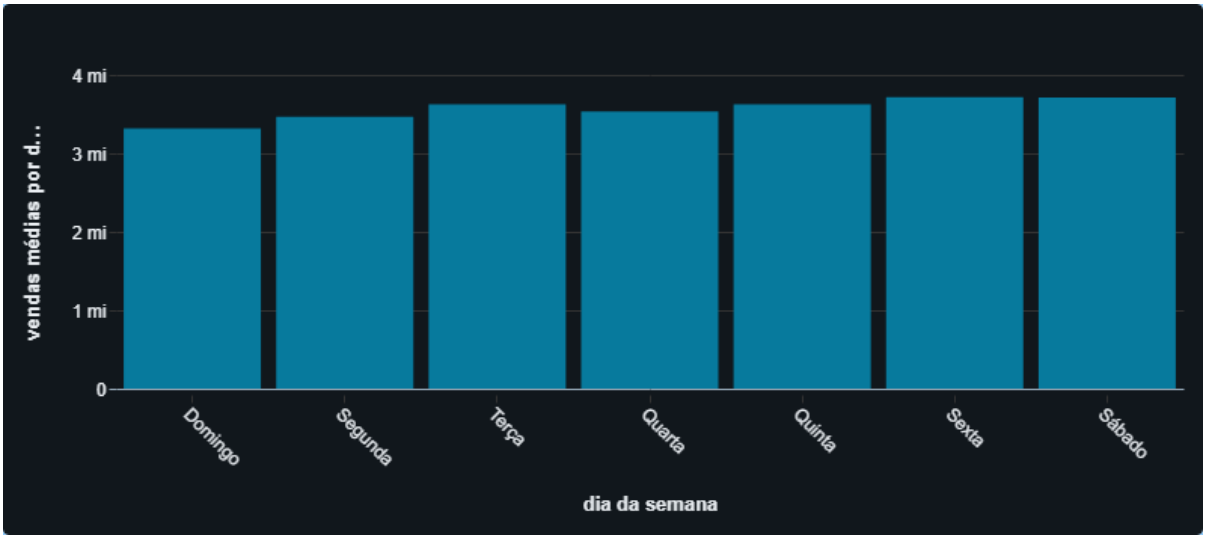

Esse gráfico indica as vendas médias por dias da semana